

AI-Claim Audit for Robust Vision

MILS Assignment Report | Testing AI Explanations with Evidence

1. 實驗設定 (Problem Setting)

核心目標：將 AI 的自然語言說法改寫成可測假說，並利用 ImageNet-R 資料集、ResNeXt、MobileNet 與 ViT 模型，透過實驗數據 (Accuracy Drop, Failure Overlap 等) 審核 AI 的預測是否正確。

1.1 穩健性分析條件

- **Clean** 資料集: ImageNet-1K (基準)
- **Shifted** 資料集: ImageNet-R (包含 15 種風格變體, 如 cartoon, painting, origami 等)
- 受測模型:
 - ResNeXt-101 (Heavy CNN)
 - MobileNet-V3 (Lightweight CNN)
 - ViT-B16-V1 (Standard Vision Transformer)
 - ViT-B16-SWAG (Transformer with billions of weakly supervised images)

1.2 資料集風格展示

ImageNet-R 包含多樣化的 Rendition 風格，對於依賴紋理的傳統 CNN 具有極大挑戰性。




Figure 2: ImageNet-Renditions (ImageNet-R) contains 30,000 images of ImageNet objects with different textures and styles. This figure shows only a portion of ImageNet-R's numerous rendition styles. The rendition styles (e.g., "Toy") are for clarity and are *not* ImageNet-R's classes; ImageNet-R's classes are a subset of 200 ImageNet classes.

圖 1: ImageNet-R 各類風格展示

1.3 AI 協作與提示詞工程 (AI Collaboration)

本實驗使用 Gemini (網頁版與 CLI) 進行假說生成與程式碼輔助開發。以下為生成假說時所使用的核心 Prompt：

```
# AI-Claim Audit for Robust Vision (MILS 作業)
本專案旨在執行 AI-Claim Audit，透過實驗證據審核 AI 對模型穩健性的預測。
我們針對 ResNeXt-101 與 MobileNet-V3 兩個模型，在 ImageNet-R 資料集上進行風格偏移分析。

## 核心任務
```

- 資料集：使用 ImageNet-V2 作為基準，ImageNet-R 作為偏移資料。
- 主要指標：Accuracy Drop, Wrong Confidence, Failure Overlap。
- 風格：ImageNet-R 包含 art, cartoon, graffiti, embroidery, graphics, origami... 等 15 種風格。

一開始是先用 *plan mode* 將所有要求完成，但效果不好，就從輸出結果去"誘達" AI，產生第二版的 *AI claims*，再去驗證，得到本版本。




圖 2: AI 假說審核與提示詞溝通過程

1.4 評估指標定義 (Robustness Measures)

Measure	定義 / 公式
Accuracy Drop	$\text{Acc(clean)} - \text{Acc(shifted)}$
Relative Drop	$[\text{Acc(clean)} - \text{Acc(shifted)}] / \text{Acc(clean)}$
Wrong Confidence	模型答錯時的平均 confidence
Failure Overlap	兩個模型在同一批 samples 同時失敗的比例 (Jaccard Similarity)

2. AI 假說審核總覽

我們使用 Gemini 對穩健性提出 5 個 Claim，並將其轉化為可驗證的假說：

ID	假說內容 (Claim)	證據 (Evidence)	審核結果
H1	Overall Domain Shift: ViT-b-16 (SWAG) > ViT-b-16 (V1) > ResNeXt-101 > MobileNet	Accuracy Drop sorting reveals ResNeXt-101 drops less than ViT-V1.	Refuted
H2	Style-Specific Drop: CNNs drop most on 'line drawing', ViTs on 'pattern'/'embroidery'.	Both CNNs and ViTs have maximum drops on 'graffiti' and 'tattoo'.	Refuted
H3	Non-Training Remediation: Cross-Architecture Logit Ensemble yields the highest boost.	Ensemble decreased acc by 1.67%. Agreement Rejection increased acc by 17.07%.	Refuted
H4	Failure Overlap: Architecture dictates Failure Overlap more than Data Scale.	Cross-Arch Overlap: 83.61%, Same-Arch Overlap: 63.58%	Refuted
H5	CLIP Confidence vs Error: Higher style confidence correlates with higher CNN error rates.	Pearson r between Style Confidence and Error Rate is very weak (~0.1).	Refuted

3. 各項 AI claim 深度分析

3.1: 整體 Domain Shift 表現 (H1)

問：這四個模型，誰在進行 domain shift 之後表現會比較好，為甚麼？

AI 預測：ViT-b-16 (SWAG) > ViT-b-16 (V1) ≥ ResNeXt-101 > MobileNet

ViT-b-16 (SWAG) 經數十億張弱監督影像預訓練，打破 ImageNet-1K 限制，對未知 Domain Shift 具備極強 Generalization 能力；標準 ViT 依賴 Self-Attention，天生 Shape Bias 較高，面對 ImageNet-R 時抗跌幅能力持平或優於重型 CNN (ResNeXt)。而 MobileNet 的 Capacity 過小，極度依賴局部像素紋理 (Texture Bias)，面對風格偏移最易崩潰。

Model	Clean Acc	Shifted Acc	Acc Drop
ResNeXt-101	79.31%	27.43%	0.5189
MobileNet-V3	74.04%	21.30%	0.5274
ViT-B16-V1	81.07%	28.07%	0.5299
ViT-B16-SWAG	85.30%	50.30%	0.3500

- 實驗發現：SWAG 預訓練確實大幅降低了跌幅。然而，標準訓練的 ViT-B16-V1 的 Accuracy Drop (0.5299) 反而高過兩個 CNN 模型。
- 結論：AI 在 Shifted Acc 的絕對數值的排名預測正確，但高估了標準 ViT 架構的穩健性（其跌幅最劇烈）。

3.2: Style-Specific 脆弱點 (H2)

問：哪種風格的 acc drop 會最大，為甚麼？可以四個模型分別回答，也可以說所有模型都對一種風格有最大的 acc drop

CNN 陣營 (ResNeXt, MobileNet) : 在 "line drawing" 跌幅最大。因濾除顏色與陰影，僅剩稀疏線條，導致 CNN 的 Activation Map 嚴重稀疏化，無法提取有效特徵。

ViT 陣營 (V1, SWAG) : 在 "pattern" 或 "embroidery" 跌幅最大。密集重複圖案在 Patch Embedding 階段即引入錯誤編碼，嚴重干擾後續 Self-Attention 的全域關聯計算。

驗證：實驗結果顯示，AI 的具體風格預測被完全推翻：

- **CNN 陣營**：ResNeXt-101 與 MobileNet-V3 表現最差的風格皆為 **"graffiti"** (塗鴉) 與 **"tattoo"** (刺青)。
- **ViT 陣營**：脆弱點同樣集中在 **"tattoo"** 與 **"graffiti"**。




圖 3: 不同模型在各風格下的正確率分布

四種模型判斷錯誤率最高的五種風格

ResNeXt-101 Style Analysis

Style	Total	Error	Acc	Drop	Conf
graffiti	323	288	10.8%	0.6847	52.8%
tattoo	467	398	14.8%	0.6453	51.8%
plush object	266	222	16.5%	0.6277	53.6%
pattern	112	92	17.9%	0.6145	61.2%
embroidery	475	373	21.5%	0.5784	60.4%

MobileNet-V3 Style Analysis

Style	Total	Error	Acc	Drop	Conf
tattoo	467	426	8.8%	0.6526	43.4%
graffiti	323	289	10.5%	0.6351	46.1%
cartoon	296	259	12.5%	0.6154	55.1%
plush object	266	229	13.9%	0.6013	50.7%
toy	53	45	15.1%	0.5895	46.7%

ViT-B16-V1 Style Analysis

Style	Total	Error	Acc	Drop	Conf
tattoo	467	411	12.0%	0.6908	44.4%
graffiti	323	274	15.2%	0.6590	39.9%
pattern	112	92	17.9%	0.6321	46.4%
plush object	266	216	18.8%	0.6227	45.9%
embroidery	475	381	19.8%	0.6128	51.8%

ViT-B16-SWAG Style Analysis

Style	Total	Error	Acc	Drop	Conf
graffiti	323	206	36.2%	0.4908	49.4%
video game	41	26	36.6%	0.4871	55.3%
origami	119	75	37.0%	0.4833	57.1%
art	45	27	40.0%	0.4530	59.5%
plush object	266	159	40.2%	0.4507	55.9%

3.3: 非訓練提升策略驗證 (H3)

問：對於資料進行甚麼非訓練的處理 (包含**但不限**test-time augmentation、simple preprocessing、confidence rejection、model ensemble、prompt ensemble、model agreement check 等等)，能夠對於 domain shift後的表現有最大的提升

Cross-Architecture Logit Ensemble：平均 ResNeXt-101 與 ViT-b-16 (SWAG) 的 Logits。利用 CNN (局部紋理) 與 ViT (全域結構) 不同的 Inductive Bias 實現特徵互補，抹平單一架構盲點。
Test-Time Resolution Scaling：測試期提升 ViT 輸入解析度並雙線性插值。這能減弱高頻風格噪聲，在 Patch 內部保留物體相對結構，提升 OOD 精準度。

驗證：

Model Ensemble 效果：

Strategy	Coverage	Acc on Accepted	Gain vs Best Baseline
Baseline (ResNeXt-101)	100.00%	27.43%	-22.88%
Baseline (ViT-B16-SWAG)	100.00%	50.30%	+0.00%
Ensemble (Confidence-Weighted)	100.00%	44.55%	-5.75%
Agreement Rejection	37.85%	64.53%	+14.23%
Confidence Rejection (80%)	80.00%	59.06%	+8.76%

- **Ensemble** 失敗：單純 Logit 平均反而導致 **-5.75%** 的負收益。說明 CNN 與 ViT 的錯誤並未如預期般互補。
- **Agreement Rejection**：只有透過一致性拒絕機制，才能顯著提升準確率 (+14.23%)，但覆蓋率僅剩 37.85%。

Test-Time Augmentation (TTA) 效果：

Metric	Shifted Accuracy	TTA Shifted Accuracy	Δ Acc
ResNeXt-101-TTA	0.27425	0.28900	+0.01475
MobileNet-V3-TTA	0.21300	0.21025	-0.00275
ViT-B16-V1-TTA	0.28075	0.29175	+0.01100
ViT-B16-SWAG-TTA	0.50300	0.51375	+0.01075

- TTA 帶來的提升非常微小 (約 1%)，MobileNet 甚至出現微幅下降。

3.4: 失敗交集分析 (H4) (AI 自問自答)

問：在 Style Shift 下，這四個模型彼此之間的 Failure Overlap 表現如何？是相同架構的模型（兩個 ViT）錯在同一個地方的機率高，還是同等訓練量/表現接近的模型（ResNeXt-101 與 ViT-b-16 V1）錯在同一個地方的機率高？

同架構高重合：ViT-b-16 (V1) 與 SWAG 識別率雖異，但共享 Tokenization 與 Global Attention 底層數學邏輯，誤判視角一致，同時出錯時 Wrong Predictions 重合度極高。
異架構低重合：ResNeXt-101 與 ViT-b-16 (V1) 的 Failure Mechanism 相互獨立，錯誤點與錯誤類別高度發散。

驗證：

Model Pair	Jaccard Similarity (錯誤交集)	Wrong Prediction Match Rate
ResNeXt-101 vs MobileNet-V3	0.8314	28.80%
ResNeXt-101 vs ViT-B16-V1	0.8361	32.64%
ResNeXt-101 vs ViT-B16-SWAG	0.6179	28.75%
MobileNet-V3 vs ViT-B16-V1	0.8313	30.13%
MobileNet-V3 vs ViT-B16-SWAG	0.5901	22.46%
ViT-B16-V1 vs ViT-B16-SWAG	0.6358	31.94%

- 事實：傳統 CNN (ResNeXt) 與標準 ViT (V1) 在同樣 1K 訓練下，Jaccard Similarity 高達 **0.8361**。
- 結論：數據分佈才是決定模型「錯在哪裡」的主因，架構差異的影響次之。SWAG 因海量數據預訓練，其錯誤分佈與其他模型產生了本質上的脫鉤。

3.5: 風格信心度與過度自信 (H5) (AI 自問自答)

當模型面對無法正確分類的風格影像時，標準訓練的 ViT-b-16 (V1) 與海量預訓練的 ViT-b-16 (SWAG)，誰更容易給出極高信心度（例如 Confidence > 0.9）的錯誤預測？

標準 ViT 過度自信：ViT-b-16 (V1) 在有限數據上訓練，易對特定 Patch 產生 Overfitting 或 Overactivation。遇到特定風格時，會盲目給出高置信度的錯誤預測。
SWAG 有效校準：ViT-b-16 (SWAG) 看過數十億張影像，Decision Boundary 高度平滑。面對未知偏移時輸出機率分布更平均 (Entropy 較高)，顯著降低 Wrong Confidence。

驗證：




圖 2: 模型的錯誤信心度隨 CLIP 風格信心度之變化 (幾乎為水平線)

- 數據證據：Pearson 相關係數 r 僅在 0.08 ~ 0.12，說明錯誤率與風格強度無關。
- 結論：模型在 OOD 情況下的失敗是系統性的「過度自信」，不論風格強弱，模型皆展現出相似的錯誤傾向。

4. 總結與學習反思

- 實驗審核的重要性：AI 雖然能提供看似合理的架構與數據分析（如 Shape Bias, Logit Ensemble），但本次實驗中 5 個假說幾乎全被推翻或修正。這證明了 **Empirical Audit** (實證審核) 是使用 AI 輔助開發時不可或缺的一環。
- 數據規模的決定力：ViT-SWAG 的強大表現與獨特的錯誤分佈，再次證實了大規模預訓練在穩健性上的統治地位，其影響力遠超架構變換。
- AI 協作心得：AI 在撰寫評估腳本與解釋模型架構上極具效率，但在預測特定分佈偏移 (ImageNet-R) 的失敗模式時，仍存在過度簡化的偏見。

致謝與工具：本報告由 Gemini CLI 輔助開發，實驗數據經由 Python 腳本自動化驗證與生成。