

AI-Claim Audit for Robust Vision

MILS Assignment Report

1. 實驗設定 (Problem Setting)

本次實驗旨在比較卷積神經網路 (CNN) 與視覺轉換器 (Transformer) 在面對分佈偏移 (Distribution Shift) 時的穩健性。我們選擇了經典的 **VGG-19** 與 **ViT-B/16** 模型，並在 ImageNet 類別子集上進行測試。

- 基準資料集 (**Clean**): ImageNet-V2
- 偏移資料集 (**Shifted**): ImageNet-R (包含卡通、素描、油畫等風格變體)
- 類別數量: 隨機選定 20 個共同類別 (如：金魚、鯊魚、公雞等)

2. 實驗環境 (Experimental Environment)

項目	內容
硬體	NVIDIA GeForce RTX 5090 (32GB VRAM)
作業系統	Linux (Ubuntu 24.04 核心)
軟體版本	Python 3.12.3, PyTorch 2.11.0, CUDA 12.8
執行模式	GPU Inference (NVIDIA RTX 5090 / CUDA)

3. 評估結果 (Quantitative Results)

指標	VGG-19 (CNN)	ViT-B/16 (Transformer)
----	--------------	------------------------

Clean Accuracy	75.50%	84.00%
Shifted Accuracy	17.00%	28.50%
Accuracy Drop	0.5850	0.5550
Avg Wrong Confidence	41.68% (All)	46.56% (All)

4. AI Claim Audit (假說審核)

下表展示了我們對 AI 提出之假說的驗證結果：

ID	假說內容 (Claim)	證據 (Evidence)	審核結果 (Decision)
C1	ViT has a smaller average Accuracy Drop on ImageNet-R than VGG-19.	VGG Drop: 0.5850, ViT Drop: 0.5550	Supported
C2	VGG-19's Accuracy Drop is largest on 'cartoon' and 'sketch' sub-categories.	Max VGG Drop on plush object (0.7550).	Refuted
C3	Wrong Confidence is higher for VGG-19 than ViT.	VGG Wrong Conf: 0.3443, ViT Wrong Conf: 0.3625	Refuted
C4	Both models have their highest Accuracy Drop on 'sculpture' renditions.	VGG Max: plush object, ViT Max: plush object	Refuted
C5	The failure overlap between ViT and VGG-19 is less than 50%.	Overlap Ratio: 80.17%	Refuted

5. 深入分析與觀察 (In-depth Analysis)

5.1 穩健性差異

實驗結果支持了 **ViT** 比 **VGG-19** 更具穩健性 的說法。ViT 的 Accuracy Drop 為 0.5550，優於 VGG-19 的 0.5850。這可能歸功於 Transformer 的全局注意力機制，使其能捕捉到比局部卷積更具辨識度的形狀特徵，而非僅依賴局部紋理。

5.2 過度自信問題 (Overconfidence)


令人意外的是，ViT 在答錯時的平均信心值比 VGG-19 更高 (Refuted C3)。這顯示 ViT 雖然準確率較高，但一旦遇到不熟悉的風格偏移，其預測往往更具誤導性，這在安全關鍵的應用中是一個潛在風險。

5.3 錯誤模式的重疊 (Failure Overlap)


儘管兩者架構迥異，但在 ImageNet-R 上的失敗案例重疊率高達 **80.17%**。這說明模型在面對極端的風格變換時，往往在相同的困難樣本上卡關，顯示目前的視覺模型在處理特定「本質性」缺失上仍有共同的弱點。

6. 失敗案例分析 (Failure Analysis)

以下展示了模型在風格偏移資料集中的典型錯誤：



VGG-19 失敗案例 #1 (Shifted)



ViT-B/16 失敗案例 #1 (Shifted)



VGG-19 失敗案例 #2 (Shifted)



ViT-B/16 失敗案例 #2 (Shifted)

觀察：許多錯誤發生在「素描」或「高抽象度」的影像中。模型往往將線條特徵誤認為其他類別（例如將細長線條誤認為針或天線）。

7. 結語與反思 (Reflection)

AI 對我的幫助： AI 協助我快速產生了可測試的假說，並提供了實作穩健性評估框架的腳本雛形。

AI 的誤導之處： AI 最初預測 VGG-19 會有較高的 Wrong Confidence，且認為兩模型失敗案例會大不相同。然而實驗證明 ViT 更加過度自信，且兩者失敗模式高度一致。這顯示了「實驗驗證」在 AI 時代的重要性——我們不能盲目相信 AI 的推論，必須以數據說話。