

AI-Claim Audit for Robust Vision

MILS Assignment Report

1. 實驗設定 (Problem Setting)

本次實驗旨在比較卷積神經網路 (CNN) 與視覺轉換器 (Transformer) 在面對分佈偏移 (Distribution Shift) 時的穩健性。我們選擇了經典的 **VGG-19** 與 **ViT-B/16** 模型，並在 ImageNet 類別子集上進行測試。

- 基準資料集 (**Clean**): ImageNet-V2
- 偏移資料集 (**Shifted**): ImageNet-R (包含卡通、素描、油畫等風格變體)
- 類別數量: 隨機選定 20 個共同類別 (如: 金魚、鯊魚、公雞等)

2. 實驗環境 (Experimental Environment)

項目	內容
硬體	NVIDIA GeForce RTX 5090 (32GB VRAM)
作業系統	Linux (Ubuntu 24.04 核心)
軟體版本	Python 3.12.3, PyTorch 2.11.0, CUDA 12.8
執行模式	GPU Inference (NVIDIA RTX 5090 / CUDA)

3. 評估結果 (Quantitative Results)

指標	VGG-19 (CNN)	ViT-B/16 (Transformer)
Clean Accuracy	75.50%	84.00%
Shifted Accuracy	17.00%	28.50%
Accuracy Drop	0.5850	0.5550
Avg Wrong Confidence	41.68% (All)	46.56% (All)

4. AI Claim Audit (假說審核)

下表展示了我們對 AI 提出之假說的驗證結果：

ID	假說內容 (Claim)	證據 (Evidence)	審核結果 (Decision)
C1	ViT has a smaller average Accuracy Drop on ImageNet-R than VGG-19.	VGG Drop: 0.5850, ViT Drop: 0.5550	Supported
C2	VGG-19's Accuracy Drop is largest on 'cartoon' and 'sketch' sub-categories.	Max VGG Drop on plush object (0.7550).	Refuted
C3	Wrong Confidence is higher for VGG-19 than ViT.	VGG Wrong Conf: 0.3443, ViT Wrong Conf: 0.3625	Refuted
C4	Both models have their highest Accuracy Drop on 'sculpture' renditions.	VGG Max: plush object, ViT Max: plush object	Refuted
C5	The failure overlap between ViT and VGG-19 is less than 50%.	Overlap Ratio: 80.17%	Refuted

5. 深入分析與觀察 (In-depth Analysis)

5.1 穩健性差異

實驗結果支持了 **ViT** 比 **VGG-19** 更具穩健性的說法。ViT 的 Accuracy Drop 為 0.5550，優於 VGG-19 的 0.5850。這可能歸功於 Transformer 的全局注意力機制，使其能捕捉到比局部卷積更具辨識度的形狀特徵，而非僅依賴局部紋理。

5.2 過度自信問題 (Overconfidence)


令人意外的是，ViT 在答錯時的平均信心值比 VGG-19 更高 (Refuted C3)。這顯示 ViT 雖然準確率較高，但一旦遇到不熟悉的風格偏移，其預測往往更具誤導性，這在安全關鍵的應用中是一個潛在風險。

5.3 錯誤模式的重疊 (Failure Overlap)


儘管兩者架構迥異，但在 ImageNet-R 上的失敗案例重疊率高達 **80.17%**。這說明模型在面對極端的風格變換時，往往在相同的困難樣本上卡關，顯示目前的視覺模型在處理特定「本質性」缺失上仍有共同的弱點。

6. 失敗案例分析 (Failure Analysis)

以下展示了模型在風格偏移資料集中的典型錯誤：



VGG-19 失敗案例 #1 (Shifted)



ViT-B/16 失敗案例 #1 (Shifted)



VGG-19 失敗案例 #2 (Shifted)



ViT-B/16 失敗案例 #2 (Shifted)

觀察：許多錯誤發生在「素描」或「高抽象度」的影像中。模型往往將線條特徵誤認為其他類別（例如將細長線條誤認為針或天線）。

7. 結語與反思 (Reflection)

AI 對我的幫助： AI 協助我快速產生了可測試的假說，並提供了實作穩健性評估框架的腳本雛形。

AI 的誤導之處： AI 最初預測 VGG-19 會有較高的 Wrong Confidence，且認為兩模型失敗案例會大不相同。然而實驗證明 ViT 更加過度自信，且兩者失敗模式高度一致。這顯示了「實驗驗證」在 AI 時代的重要性——我們不能盲目相信 AI 的推論，必須以數據說話。