

AI-Claim Audit for Robust Vision

MILS Assignment Report

1. 實驗設定 (Problem Setting)

本次實驗旨在審核 AI 對於不同視覺模型架構在面對分佈偏移 (Distribution Shift) 時的穩健性預測與解釋是否正確。我們選用了 4 個預訓練模型，並在 ImageNet 類別子集上進行嚴格的量化測試與分析。

- 基準資料集 (**Clean**): ImageNet-V2
- 偏移資料集 (**Shifted**): ImageNet-R (包含 16 種如卡通、塗鴉等風格變體)
- 受測模型: ResNeXt-101, MobileNet-V3, ViT-B16-V1, ViT-B16-SWAG
- 預訓練權重: 使用官方 ImageNet-1K V1 及 SWAG 權重以對齊比較基礎。

2. 實驗環境 (Experimental Environment)

項目	內容
硬體	NVIDIA GeForce RTX 5090 (32GB VRAM)
軟體	PyTorch 2.11.0, CUDA 12.8
執行模式	GPU Inference (CUDA)

3. 基礎穩健性指標評估 (Robustness Metrics)

指標 (Metrics)	ResNeXt-101	MobileNet-V3	ViT-B16-V1	ViT-B16-SWAG
Clean Accuracy	79.31%	74.04%	81.07%	85.30%
Shifted Accuracy	27.43%	21.30%	28.07%	50.30%
Accuracy Drop	0.5189	0.5274	0.5299	0.3500
Relative Drop	65.42%	71.23%	65.37%	41.03%
Avg Robust Acc	25.99%	20.25%	26.13%	46.78%
Worst-case Acc	10.84%	8.78%	11.99%	36.22%
Wrong Conf	51.56%	44.90%	41.03%	45.74%
Rej Robust (80%)	32.94%	25.81%	33.81%	59.06%

4. 假說審核與證據 (AI Claim Audit)

H1: 整體 Domain Shift 表現

Claim: ViT-b-16 (SWAG) > ViT-b-16 (V1) > ResNeXt-101 > MobileNet (就穩健性而言)

Evidence: 依據 Accuracy Drop 指標 (越小越穩健)，四個模型的降幅排序為：ViT-B16-SWAG (0.3500), ResNeXt-101 (0.5189), MobileNet-V3 (0.5274), ViT-B16-V1 (0.5299)。

Decision: Refuted (部分推翻) - 雖然 SWAG 的降幅最小，但高參數卷積模型 ResNeXt-101 的穩健性實際上優於標準的 ViT-V1，打破了單純「Transformer 架構必然決定較高穩健性」的說法。

H2: Style-Specific 脆弱點

Claim: CNNs 最大的 Drop 在 line drawing，而 ViTs 最大的 Drop 在 pattern / embroidery。

Evidence: 根據分析，四個模型表現最差 (Worst-case) 的風格分別為：

- ResNeXt-101: graffiti
- MobileNet-V3: tattoo
- ViT-B16-V1: tattoo
- ViT-B16-SWAG: graffiti

Decision: Refuted (推翻) - 不論是 CNN 陣營還是 ViT 陣營，其最脆弱的風格高度一致 (皆為 graffiti 或 tattoo)，並未如 AI 預期般在不同材質 (如 line drawing 或 pattern) 上產生分歧。

H3: 免重新訓練的補救措施模擬

Claim: Cross-Architecture Logit Ensemble yields the highest boost.

Evidence:

Strategy	Coverage	Accuracy on Accepted	Gain vs Best Baseline (SWAG)
Baseline (ResNeXt-101)	100.00%	27.43%	-22.88%
Baseline (ViT-B16-SWAG)	100.00%	50.30%	+0.00%
Ensemble (Confidence-Weighted)	100.00%	44.55%	-5.75%
Agreement Rejection	37.85%	64.53%	+14.23%
Confidence Rejection (80%)	80.00%	59.06%	+8.76%

Decision: Refuted (推翻) - 實驗證明單純的 Confidence-Weighted Ensemble 反而拉低了 SWAG 模型的原始表現 (-1.67%)。真正能大幅提升系統可靠度的是 **Agreement Rejection (一致性拒絕)**，它在保留部分高可信度資料的情況下，讓子集準確度顯著提升 (+17.07%)。

H4: 失敗重疊率 (Failure Overlap)

Claim: Architecture dictates Failure Overlap more than Data Scale.

Evidence: 我們計算了模型在預測錯誤時的 Jaccard Similarity：


- **Cross Pair (不同架構, 相似訓練):** ResNeXt-101 vs ViT-B16-V1 錯誤重疊率為 **83.61%**
- **ViT Pair (同架構, 不同訓練):** ViT-B16-V1 vs ViT-B16-SWAG 錯誤重疊率僅為 **63.58%**

Decision: Refuted (推翻) - 實驗完美證明了「訓練資料的規模與方式 (如 SWAG)」比「模型底層的架構 (CNN vs ViT)」更能決定模型在領域偏移下的失敗模式。相同架構不同訓練的 ViT Pair 重疊率，遠低於不同架構但訓練設定類似的 Cross Pair。

H5: CLIP 風格信心度與模型錯誤率之相關性

Claim: Higher CLIP style confidence correlates with higher CNN error rates and severe Wrong Confidence.

Evidence:



Model	Pearson r (Style Conf vs Wrong Conf)	Pearson r (Style Conf vs Error Rate)
ResNeXt-101	-0.0039	0.0939
MobileNet-V3	0.0181	0.1069
ViT-B16-V1	0.0525	0.1244
ViT-B16-SWAG	-0.0313	0.0875

Decision: Refuted (推翻) - 統計結果顯示，CLIP 的風格信心度與模型的錯誤機率或誤判信心值之間，只有極度微弱的正相關（Pearson r 僅約 0.08~0.12）。這代表「這張圖很像某種強烈風格」並不是導致模型答錯的決定性因素。

5. 失敗案例分析 (Failure Analysis)

ResNeXt-101 Fail	MobileNet-V3 Fail	ViT-B16-V1 Fail
ViT-B16-SWAG Fail		

觀察：從具體的誤判資料（如 `misclassify\_analysis.csv`）中我們發現，模型常將 `line drawing` 誤判為 `nematode` 或 `hook`，將 `tattoo` 誤判為 `Band\_Aid`。這顯示模型嚴重依賴局部形狀與皮膚背景等捷徑特徵（Shortcut features），缺乏對整體語義的理解能力。

6. 結語與反思 (Reflection)

AI 對我的幫助： AI 協助我快速梳理了穩健性評估框架，並構思了具備深度的實驗假說（如 H3 的免訓練補救、H4 的架構與資料規模之爭）。它也大幅加速了腳本開發，包含 CLIP 的 Zero-shot 風格標註整合。

AI 的誤導之處： 本次實驗的 5 個 AI Claims 幾乎全數被實驗數據推翻。AI 過於想當然地認為「架構決定一切」或「風格越明顯錯誤越嚴重」。然而實驗結果殘酷地證明：大規模弱監督訓練（SWAG）的影響力遠大於網路架構的選擇；而在面對真實世界的 Domain Shift 時，單純的模型集成可能弊大於利。這深刻提醒了我們：在 AI 時代，實驗驗證 (Empirical Audit) 比以往任何時候都更加不可或缺。